Lab 03 — Générateur de texte chaotique

Réalisé par Farahi Abderahim · HMM, Viterbi et trigramme · Corpus synthétique et UD English EWT

Problème et solution (5 lignes)

La génération produit des phrases sans réponse de référence; quelques exemples ne suffisent donc pas à en mesurer la qualité.
Un HMM génère d'abord une suite d'étiquettes grammaticales, puis les mots correspondants.
Le modèle trigramme prédit les mots à partir du contexte et peut reprendre des phrases d'entraînement.
Les métriques automatiques évaluent structure, plausibilité sujet-verbe, nouveauté et diversité sur 500 phrases.
L'application compare les modèles et utilise Viterbi pour attribuer une étiquette à chaque mot saisi.

Résultats synthétiques à T = 1.0 (500 phrases par modèle)

Modèle	Structure valide	Sujet-verbe	Nouveauté	Distinct-2
HMM simple	16,2%	14,8%	99,8%	0,198
HMM états par rôle	100,0%	60,6%	99,4%	0,148
Trigramme	57,0%	76,0%	91,2%	0,105

Le HMM simple obtient peu de structures valides (16,2 %), car un état NOUN ne distingue pas le sujet de l'objet. La séparation des états par rôle fait passer la structure à 100 %, mais n'ajoute pas la connaissance du sens : sa plausibilité sujet-verbe (60,6 %) reste sous celle du trigramme (76,0 %). Viterbi atteint 100 % sur le test synthétique, dont watch : 37/37, grâce aux 16 patrons réguliers. Pour un jouet d'écriture, T=1,5 avec les états par rôle donne plus de diversité tout en gardant la structure; pour l'autocomplétion, T=0,5 favorise des sorties plus prudentes.

Exemples générés

Réussite (structure et association plausibles) : « the happy doctors eat behind the market . » — phrase nouvelle dont le couple sujet-verbe est observé dans l'entraînement. **Échec de sens :** « the foxes lose by the school . » — patron valide, mais association sémantique étrange; les états mémorisent les rôles, pas le sens.

Test sur texte réel — UD English EWT

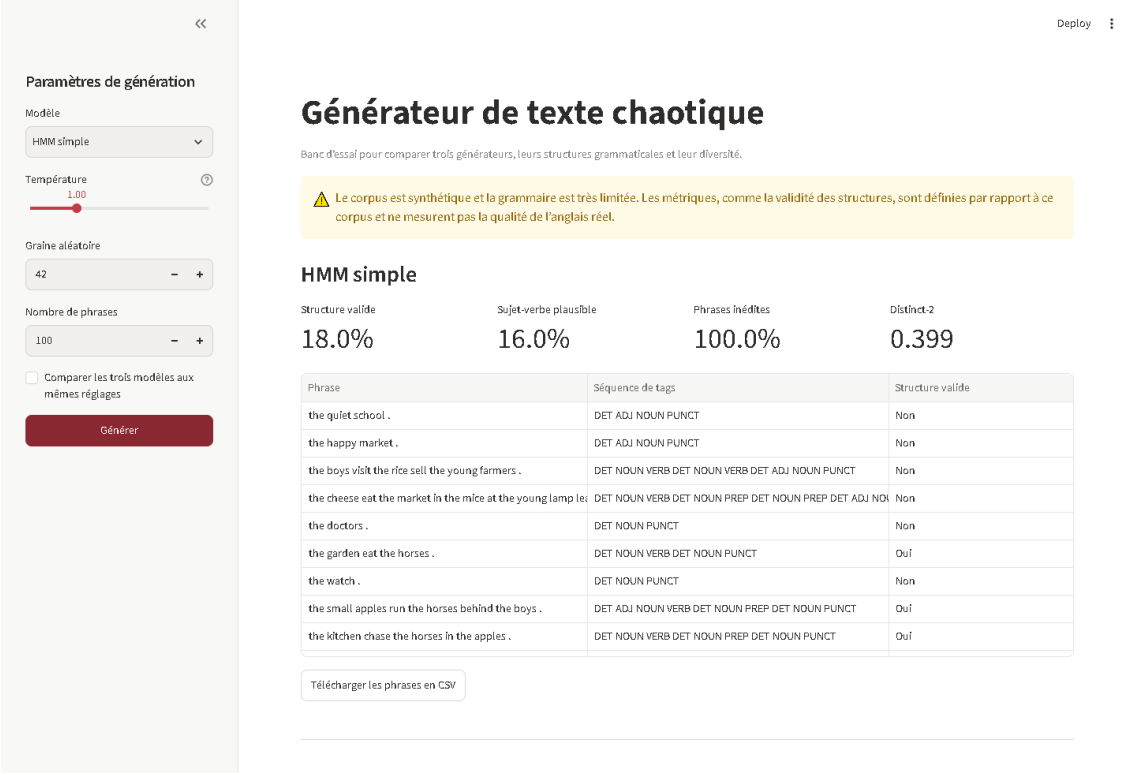
Modèle	Exactitude	Mots connus	Mots inconnus	Phrase entière
Tag le plus fréquent	86,2%	90,8%	28,6%	31,9%
HMM + Viterbi	88,0%	92,9%	28,2%	40,4%

Le HMM obtient 88,0% sur EWT contre 100 % sur le corpus synthétique, et seulement 28,2% sur les mots inconnus (7,5 % des tokens). EWT compte 17 étiquettes, 16 654 mots connus à l'entraînement et 10 359 séquences d'étiquettes distinctes : la langue réelle est bien moins régulière et contient des mots absents de l'apprentissage. La mesure actuelle est 88,0% alors que le guide indique 88,1 %; l'écart de 0,1 point est conservé tel qu'observé. Le HMM ne dépasse le tagueur majoritaire que d'environ 1,9 point.

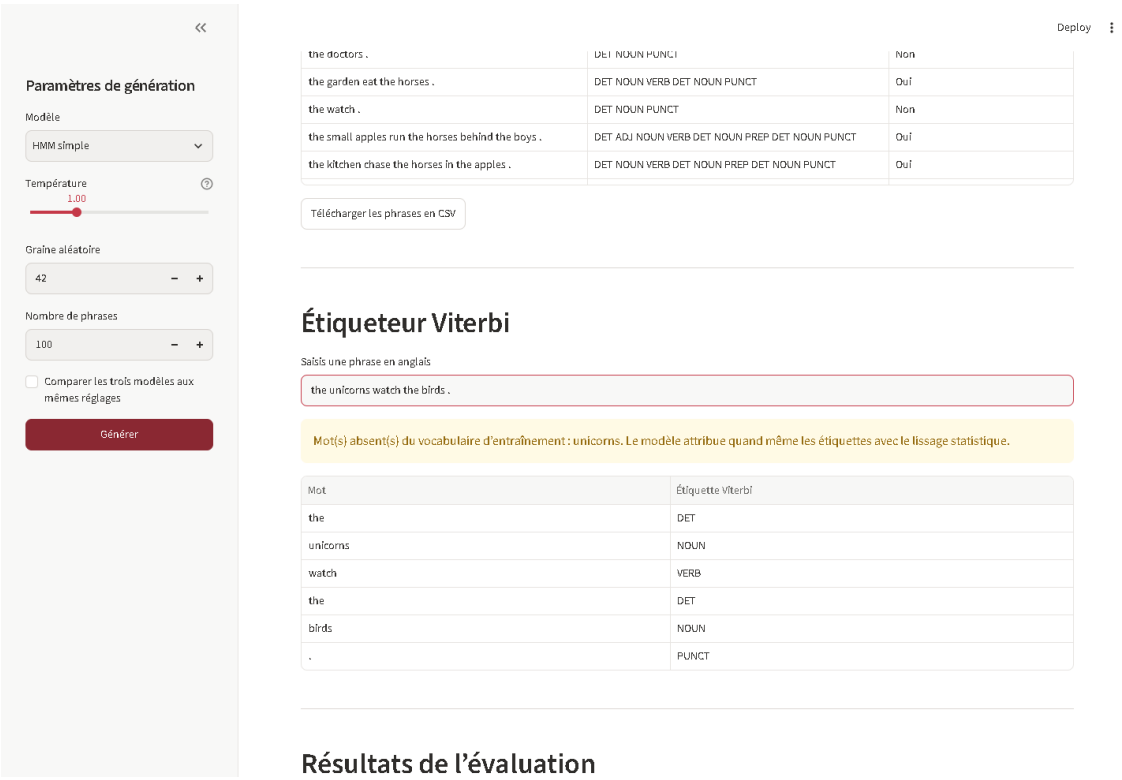
Limite : les métriques structurelles sont définies par rapport aux 16 patrons du corpus synthétique et ne mesurent pas la qualité de l'anglais réel.

Captures de l’application

Interface du générateur et test du tagueur Viterbi avec un mot hors vocabulaire.



Génération de phrases et métriques



Tagueur Viterbi et détection d’un mot inconnu