Lab 03 — Générateur de texte chaotique

Compte rendu · HMM, Viterbi et trigramme · Corpus synthétique et UD English EWT

Problème et solution (5 lignes)

La génération produit des phrases sans réponse de référence; quelques exemples ne suffisent donc pas à en mesurer la qualité.
Un HMM génère d'abord une suite d'étiquettes grammaticales, puis les mots correspondants.
Le modèle trigramme prédit les mots à partir du contexte et peut reprendre des phrases d'entraînement.
Les métriques automatiques évaluent structure, plausibilité sujet-verbe, nouveauté et diversité sur 500 phrases.
L'application compare les modèles et utilise Viterbi pour attribuer une étiquette à chaque mot saisi.

Résultats synthétiques à T = 1.0 (500 phrases par modèle)

Modèle	Structure valide	Sujet-verbe	Nouveauté	Distinct-2
HMM simple	16,2%	14,8%	99,8%	0,198
HMM états par rôle	100,0%	60,6%	99,4%	0,148
Trigramme	57,0%	76,0%	91,2%	0,105

Le HMM simple obtient peu de structures valides (16,2 %), car un état NOUN ne distingue pas le sujet de l'objet. La séparation des états par rôle fait passer la structure à 100 %, mais n'ajoute pas la connaissance du sens : sa plausibilité sujet-verbe (60,6 %) reste sous celle du trigramme (76,0 %). Viterbi atteint 100 % sur le test synthétique, dont watch : 37/37, grâce aux 16 patrons réguliers. Pour un jouet d'écriture, T=1,5 avec les états par rôle donne plus de diversité tout en gardant la structure; pour l'autocomplétion, T=0,5 favorise des sorties plus prudentes.

Exemples générés

Réussite (structure et association plausibles) : « the happy doctors eat behind the market . » — phrase nouvelle dont le couple sujet-verbe est observé dans l'entraînement. **Échec de sens :** « the foxes lose by the school . » — patron valide, mais association sémantique étrange; les états mémorisent les rôles, pas le sens.

Test sur texte réel — UD English EWT

Modèle	Exactitude	Mots connus	Mots inconnus	Phrase entière
Tag le plus fréquent	86,2%	90,8%	28,6%	31,9%
HMM + Viterbi	88,0%	92,9%	28,2%	40,4%

Le HMM obtient 88,0% sur EWT contre 100 % sur le corpus synthétique, et seulement 28,2% sur les mots inconnus (7,5 % des tokens). EWT compte 17 étiquettes, 16 654 mots connus à l'entraînement et 10 359 séquences d'étiquettes distinctes : la langue réelle est bien moins régulière et contient des mots absents de l'apprentissage. La mesure actuelle est 88,0% alors que le guide indique 88,1 %; l'écart de 0,1 point est conservé tel qu'observé. Le HMM ne dépasse le tagueur majoritaire que d'environ 1,9 point.

Limite : les métriques structurelles sont définies par rapport aux 16 patrons du corpus synthétique et ne mesurent pas la qualité de l'anglais réel.